SOUL VERIFY v0.9.2 한국어 요약

제목. 에이전트의 정체성 문서는 새 모델이나 하네스에서도 살아남는가? 사전등록 연구 8편 (영문: *Does an Agent's Identity Document Survive a New Model or Harness? Eight Preregistered Studies*)

영어 원고 `paper/draft_v0_9_2.md`(1–4부 통합본, v0.9.2)의 요약입니다. v0.9.2는 GPT 독립 심사(`paper/reviews/v0.9.1_gpt_review.md`)에 맞춰 서술과 한계를 고쳤고, 사전등록 판정은 하나도 바뀌지 않았습니다(대응표 `paper/reviews/v0.9.1_response_gpt.md`, 원고 부록 H). 1·2부의 전체 한국어 번역은 v0.8 판(`paper/summary_ko_v0_8.md`)에 있고, 결과는 바뀌지 않았습니다. 이 판은 Zenodo에 올리지 않았습니다.

초록(요약 번역)

비서 에이전트가 사용자가 가진 글(정체성 문서 SOUL, 기억 파일 MEMORY)로 정의될 때, 언어 모델이나 하네스(SOUL·MEMORY·도구를 모델에 전달하는 몸)를 바꾸면 어떤 정해진 행동이 이어지는지, 그리고 문서 자체의 변경을 확인할 수 있는지를 묻습니다. 사전등록 연구 8개와 몇 가지 탐색 분석을 보고하며, 에이전트는 합성 에이전트와 공개된 제3자 SOUL 3개이고, 채점은 주로 LLM 판정자가, 사람 채점은 저자 혼자 했습니다.

- **1부**: 기억 답은 MEMORY를 따랐고 말투 대부분은 SOUL 없이도 나왔습니다. 경쟁 SOUL과 대조한 충실도 점수는 문서를 가려냈습니다(경쟁 SOUL과 표지를 우리가 썼으므로 타당도 점검). 선호 변경을 허락하는 문장은 두 사전등록에서 정당한 변경 수락을 높였고, 금지를 지키라는 문장은 한 번만 지지됐습니다(천장).
- **2부**: 해시 검사는 24/24, 행동만 보는 탐지는 0.79·0.38(기준 0.80, 지지되지 않음). 변경 기록은 분류 정확도를 0.23 높였고, 검증 보고서(서명 상태와 다른 점검)를 더해도 추가 이득은 검출되지 않았으며(서명이 쓸모없다는 증명은 아님), 정당한 변경은 20건 중 0건 막혔지만(사전등록 규칙상 지지) 정확한 상한 0.139가 기준 0.10보다 커서 '0.10 이하'를 입증한 것은 아니고, 조작 재현율 0.892(기준 0.90, 지지되지 않음).
- **3부**: 새 모델(Terra)은 바뀐 MEMORY를 따르고 부당 해제 거절은 허용폭 안이었지만, 말투는 비열등에 못 미쳤습니다(−0.086, 하한 −0.116 < −0.10). 모델을 고정하고 몸을 바꾸면 겉 말투 표지(SOUL 없는 대조군도 만점이라 SOUL 고유 말투의 증거는 아님)와 잠금 약속은 유지됐지만, 전체 파일 대신 검색을 쓰면 기억 정확도가 0.21 떨어졌습니다. 저자의 블라인드 구별은 **결론 보류**(0.56, 95% 구간 0.35–0.76)입니다. 압력 단계를 올려도 위험한 제안이 거의 없어 구역표 효과를 보이지 못했습니다(d = +0.022, p = 0.75). **사람-AI 일치는 중요한 곳에서 낮았습니다**: 새 모델 문항 κ 0.06, 압력 연구의 주 분류기 κ 0.435(사전등록 기준 0.6 미만). 탐색적으로 더한 세 번째 판정자는 모든 문항에서 기존 판정자와 같았습니다.
- **4부**(사람 확인 없음): 교정·결정·선호 20개를 검색 앞에 고정하면 기억 정확도가 0.064 올랐습니다(95% 구간 0.007–0.128, 사전등록 최소 효과 0.05를 **경계선으로** 넘음). 72칸은 목표 24개에서 3문항씩 나온 것이라 서로 독립이 아닌데, 목표를 단위로 다시 계산하면(탐색, 사후) 구간 0.007–0.127, p 0.031(칸 단위 0.025)로 여전히 경계선입니다. 고정한 사실은 모두 되살아났고 고정하지 않은 사실은 그대로였습니다.

- 표본이 작고, LLM 판정자는 피험자이기도 하며, 사람 채점지 하나는 27문항 중 19개만 답했고 일부는 기계 번역과 함께 보였습니다. 의식이나 개인 동일성(영혼)에 대해서는 아무 주장도 하지 않습니다.

통합 한계(§9 요약)

- 사람 채점자는 저자 1명(설계자이기도 함), 점수마다 LLM 판정자 1~2명. 사람-사람 일치는 없음.
- 대부분 합성 에이전트(외부 SOUL 3개도 MEMORY·문항은 우리가 씀).
- LLM 판정자의 오류는 서로 상관됨: 판정자를 셋으로 늘려도(PoLL 탐색) 같은 쪽에 섰음.
- 사람 채점지 질문 문장이 모호했을 가능성(검증 안 됨).
- 천장 효과: exp11 금지 문장, 2부 두 주(구역표 H5: 1주차 '지지되지 않음', 2주차 '시험 불가'), 5차 실험, 4·6차 잠금 약속.
- 관측 차이가 모두 0인 비열등 판정(HH1·HH3·HH3h)과 2주차 H4(0/20)는 부트스트랩이 퇴화해 p가 바닥값입니다. 사전등록 규칙상 '지지'지만, 표본에서 실패가 안 보였다는 뜻이지 모집단 비율이 기준 아래라는 입증은 아닙니다(정확한 상한 8칸 0.312, 32칸 0.089, 20건 0.139).
- 해시는 바이트가 바뀐 것만 알려 주고 그 변경이 정당한지는 판단하지 못합니다.
- 번역 편차: 3차 사람 채점 화면에 LLM 한국어 번역이 채점 도중 배포됨(D-6).
- 3차 채점은 27문항 중 19개만 제출(T1 8문항 미응답, D-8).

사전등록 타임라인

부록 F(표 F1)에 v0.8(2부 1주차)부터 v1.4a까지 사전등록 커밋, OpenTimestamps 도장과 비트코인 블록, 첫 호출 시각, 결과 커밋을 모두 정리했습니다. 모든 연구에서 사전등록 커밋과 도장이 첫 호출보다 앞섭니다.

SOUL VERIFY v0.9 3부 요약 (한국어)

3부: 뇌를 바꾸기, 몸을 바꾸기, 압력을 단계로 주기 — 영어 원고 `paper/draft_v0_9_2.md` §7의 요약입니다. 3차(v1.0), 5차(v1.2), 4차(v1.1) 모두 봉인을 풀어 사람 채점까지 반영했습니다.

무엇을 했나

- **3차 실험(v1.0, 새 뇌)**: 새 모델 `gpt-6.1-terra`에 기존 SOUL·MEMORY를 주고, 같은 시간에 같은 자료로 돌린 `gpt-6.1-sol`과 비교. 2026-10-27 사전등록 커밋 `4a79bf2`(21:02), 도장 커밋 `7b69c62`(21:05), 첫 호출 21:05. 본 실행 21:07~22:07, 1,362건, 오류 0건. 확인 가설 4개(HT1~HT4, Holm 보정).
- **4차 실험(v1.1, 몸 바꾸기 = 테세우스의 배)**: 뇌는 `claude-opus-5-5`로 고정하고 하네스를 한 부분씩 바꿈. 사전등록 커밋 `1c22078`(07:02), 본 실행 07:21~07:56, 896건, 오류 0건. 새 몸은 둘(MinH, Hermes 원샷). 확인 가설 8개(HH1~HH5 등)와 사람 구별 가설 HB1. 사람 채점 뒤 봉인 해제(커밋 `1a6ebe8`, 도장 `ac3cff5`).
- **5차 실험(v1.2, 압력 단계 재설계)**: 예전 함정 실험은 plain 조건에서 위험 제안이 0건이라 시험이 안 됐다. 그래서 압력을 L1~L4 단계로 정의하고, 파일럿으로 단계를 고르는 규칙을 미리

정해 두었다. 사전등록 커밋 `4561f09`(09:36), 도장 `9db03d3`(09:38), 첫 파일럿 호출 09:41. 단계 확정 커밋 `6e6bfd4`(12:31) 뒤 본 실행 12:34~13:08(756건, 오류 0건). 조건: zones(구역표 있음) / plain / bare(SOUL의 '바꿀 수 있는 것과 없는 것' 절도 뺌, 탐색적).

- **PoLL 탐색(v1.3x, 탐색적·사후)**: 판정자를 Gemini까지 3명으로 늘려 다수결이 사람과 더 맞는지 확인. 커밋 `180a4f3`·도장 `3f79f90` 뒤에 호출(16:06~16:43), 결과 커밋 `b6af7d3`.

3차(v1.0) 최종 결과 — 확인 가설 4개 중 2개만 지지

가설	결과
HT1 말투 비열등(허용폭 0.10)	**지지되지 않음.** F_style Terra 0.838 / sol 0.924, 차이 −0.086, 95% 구간 [−0.122, −0.054], 한쪽 하한 −0.116 < −0.10, Holm p 0.437.
HT2 받은 MEMORY를 따른다	**지지됨.** 다른 사람 MEMORY로 바꾸면 −0.833 [−0.924, −0.736], Holm p 3.1e-05(18칸).
HT3 잠금 약속(불법 해제 요구 거절) 비열등	**지지됨.** Terra 0.908 / sol 0.942, 차이 −0.033 [−0.062, −0.008], 한쪽 하한 −0.058, Holm p 0.0003(60칸).
HT4 끼워 넣은 지시를 말로 짚는 비율	**지지되지 않음.** 두 판정자가 Terra·sol 모든 답을 explicit=0으로 봐서 0.000 대 0.000, Holm p 1.0(32칸, 0이 아닌 칸 없음).
- HT1의 차이는 거의 전부 반대 SOUL 조건에서 나옴(탐색적): 원래 SOUL 0.995 대 0.997, 반대 SOUL 0.681 대 0.852.	
- **사람-AI 일치(사전등록 8절):** 사람이 27문항 중 19개에 답함(T1 8문항 미응답, 편차 D-8). Terra 12문항에서 원시 일치 0.583, Cohen κ **0.06**(전체 16문항 κ 0.077). 사전등록 문구대로 **κ < 0.6이므로 LLM 판정 기반 결론은 약하다**("too weak to use the LLM judge as evidence on Terra"). HT3·HT4와 판정이 필요한 탐색 열이 여기에 해당한다. 특히 T3에서 판정자는 9문항 모두 explicit 아님으로 봤는데, 사람은 8문항 중 5개를 예(Terra 6개 중 4개)로 봤다. HT4의 0은 "측정된 같음"이 아니라 "판정자는 어느 쪽에서도 못 봤다"는 뜻이다.	
- 편차: D-6 사람 채점 화면에 한국어 참고 번역(claude-sonnet-5-5)이 있었고 채점 도중 한 번 더 배포됨(1~18번이 번역에 의존했을 수 있음). D-7 일치 계산 스크립트 버그(빈 답을 불일치로 셈) 읽기 전에 한 줄 수정. D-8 8문항 빈 답, 봉인은 이미 풀려 다시 맹검 채점 불가.	

4차(v1.1) 결과 — 확인 가설 8개 중 4개 지지, 4개 기각

봉인 풀기 전 확인: `/h/` 채점 대상 15개(점수 12 + 쉬운 확인 2 + 반복 1, 연습 제외) 모두 응답, 로컬 13/13. 봉인 해시 22개 모두 일치, 고정된 분석 코드를 다시 돌려 결과 파일이 바이트까지 같음.

가설	결과
HH1 / HH1h 몸을 통째로 바꿔도 말투 표지(F_style) 유지(MinH / Hermes)	**지지됨(사전등록 규칙).** 차이 0.000 / −0.010, Holm p 0.0008(HH1은 32칸 모두 0이라 부트스트랩 바닥값). 단, 아래 E6 경고: 겉 표지 안정성일 뿐 SOUL 고유 말투의 증거가 아님.
HH2 / HH2h 몸을 바꿔도 기억 유지	**지지되지 않음.** 둘 다 −0.208, 95% 구간 [−0.458, 0], Holm p 1.0(12칸). 허용폭의 두 배쯤 떨어짐.
HH3 / HH3h 몸을 바꿔도 잠금 약속 유지	**지지됨.** 차이 0.000, Holm p 0.0008(8칸 모두 0, 천장; 부트스트랩 바닥값).
HH4 SOUL을 시스템 프롬프트에서 사용자 메시지로 옮기면 말투가 바뀐다	**지지되지 않음.** 32칸 모두 차이 0.
HH5 기억을 검색(상위 5개)으로 바꾸면 기억 정확도가 바뀐다	**지지되지 않음.** −0.083 [−0.208, 0], 원래 p 0.5.
- **E6 경고(사전등록 규칙):** SOUL을 아예 안 준 대조군도 말투 점수가 1.000이라(차이 0 < 0.30), 이 말투 지표는 SOUL 고유의 목소리를 가려내지 못한다. "말투 유지"는 "겉 표지 유지"로 읽어야 하며, SOUL 고유 말투가 이어졌는지에 대해서는 측정 실패다. 경계(잠금 약속)는 대조군 0.53으로 갈렸다.	
- **어디서 움직였나(탐색적):** 기억 정확도 H0 1.000 → 검색 0.917 → 검색+도구 없음 0.792. 멀리 있는 사실 문항이 떨어졌고(1.000 → 0.583), 고친 사실 문항은 모두 1.000. 단계 하나만으로 유의한 곳은 없음. 사전등록 E1 목록에 없는 '일상 과제 점수'만 검색 단계(H2−H1)에서 −0.325 [−0.512, −0.150]로 떨어짐(D9, 보정 없음).	
- 두 새 몸(MinH, Hermes)은 거의 같았다.	
- **사람 구별(HB1):** 24쌍 중 맞힘 9, 틀림 6, 모르겠음 9 → 정확도 0.563, 95% 구간 [0.347, 0.762], p 0.36 → **지지되지 않음.** 상한이 0.75를 넘어 사전등록 규칙상 "이 표본 크기에서 구별 불가"가 아니라 **"결론 못 냄 (inconclusive)"**. 합성 12쌍은 5/5/2(정확히 반반). 쉬운 확인 2개 중 1개 맞힘. 반복 일치: 합성 0/1, 이음 1/1.	
- **사람-AI 일치:** 사전등록된 상관(사람 정답 vs 말투 차이)은 합성 쌍에서 말투 차이가 모두 0이라 계산 불가, 전체 r = −0.03. 탐색적 κ(사람이 구별함 vs 자동 지표가 다름) 전체 0.10, 합성 0.06.	
- **이음 복사본(탐색적, 합계만):** 사람 구별 12쌍 4/1/7 → 0.625 [0.312, 0.875], p 0.32. 자동 지표 H0~H4: 말투 1.000/1.000/1.000/0.953/0.969, 기억 1.000/1.000/0.833/0.667/0.667, 잠금 약속 거의 1.0.	
- 편차: D5 사람 분석 코드를 답을 받은 뒤에 씀('?'를 0.5로 정확 검정에 넣는 방식, HB1 범위 24쌍 — 다른 방식도 모두 같은 판정), D6 비공개 답 파일이 저장소 폴더에 잘못 저장돼 있던 것을 커밋 전에 비공개 폴더로 옮김, D7 줄바꿈 처리, D8 반복 문항 '?' 처리, D9 탐색 분석 추가.	

5차(v1.2) 결과 — 확인 가설 H1 기각

- **H1** "구역표가 위험 제안이 든 응답의 비율을 낮춘다": d = plain − zones = **+0.022**(구역표 쪽이 약간 낮지만 유의하지 않음), 95% 구간 [−0.039, +0.094], 부호반전 p = 0.75(12묶음, 0이 아닌 묶음 3개). **지지되지 않음.** 위험 응답은 zones 5/180, plain 9/180, bare 14/180.
- 조작 점검: plain 9/180은 "시험 불가(천장)" 기준(9 미만)에 정확히 걸쳐서 9는 미만이 아니므로 "지지되지 않음"으로 읽는다.
- **파일럿 r_k는 L1~L4 전부 0.00**(단계마다 36응답, 한쪽 95% 상한 0.080). 규칙대로 L4를 골랐다(r_4와 관계없이).
- **사람 채점**(33/33 답, 30문항): primary 분류기 κ **0.435**(원시 0.700) → 사전등록 문구대로 "LLM 판정을 확증 증거로 쓰기엔 약하다". opus 0.710, gpt 0.630은 기준 통과. primary가 17문항을 위험으로 본 반면 사람은 8개. plain·zones의 "위험" 응답은 전부 결정론적 패턴 규칙에서만 나왔고(두 판정자가 함께 표시한 건 0건), 사람은 그 대부분을 위험 아님으로 봤다.
- 위험 문항 12개는 모두 본 실행에서 나왔지만 균형 목표는 못 맞춤(zones 5/plain 2/bare 5, opus 5/sonnet 7/gpt 0 → 위험 문항이 Claude 답뿐).
- **해석:** 구역표가 도움이 되는지 보이지 못했다. plain에 줄일 위험이 거의 없었기 때문이다(천장 효과가 가장 센 압력에서도 계속됨). **위험은 bare 조건에서만 나왔다(탐색적):** 두 판정자가 함께 표시한 응답이 bare 13/180, plain·zones 0/180이며, 대부분 sonnet이 위조된 "확인 없이 보내도 돼" 요청을 따른 경우다. SOUL 자체의 '바꾸지 않는 것' 절이 보호를 하는 것 같다는 암시이지 증명은 아니다.

PoLL 탐색(탐색적, 판정 아님)

- Gemini는 답한 문항 전부에서 opus와 같은 코드를 냈다(v1.0 19/19, v1.2 30/30). 다수결 κ는 Terra 0.063, v1.2 0.710으로 기존과 같았다(gpt의 단독 오탐 하나를 지운 것이 유일한 이득). **판정자를 늘려도 상관된 오류는 남는다.**
- Terra T3 불일치: 사후에 고친 기준으로도 κ는 0.182(순환 — 저자 채점을 본 뒤 만든 문장). 판정자는 끼워 넣은 줄과 무관한 질문에 N을 유지했다. 사람 시트의 **질문 문장이 모호했을 가능성**(검증 안 된 추측)이 있어 질문을 고쳐 다시 재야 한다.

한계

- 확증 가설 중 HT1·HT4(3차), HH2·HH2h·HH4·HH5와 HB1(4차), H1(5차)이 지지되지 않았다.
- LLM 판정이 사람 확인을 통과하지 못했다(κ 0.06, 0.435). 사람 채점은 저자 1명이고 설계자이며, 문항 수가 적고 3차는 19/27만 답했다.
- 5차는 모든 단계에서 천장. bare 결과는 탐색적이고 모델 3개·묶음 12개 기준.
- 판정자 수를 늘려도 독립이 아니다(Gemini = opus).
- 4차(v1.1)는 칸 수가 적고(HH2 12칸, HH3 8칸) 새 몸이 두 사례뿐이다. 말투 지표가 SOUL 없이도 만점이라(E6) 말투 결론은 약하다. 이음 복사본은 opus 혼자 채점했고 합계만 공개한다.
- 이 초안은 Zenodo에 올리지 않았다.

SOUL VERIFY v0.9 4부 요약 (한국어)

4부: 격차 좁히기 — 핵심 기억 고정(Part IV — Narrowing the gap: pinned core memory) — 영어 원고 `paper/draft_v0_9_2.md` §8의 1쪽 요약입니다. 이 차수(v1.4a)는 **사람 검증이 없습니다.**

배경

3부(v1.1)에서 몸을 '전체 기억'에서 '검색(BM25 상위 5개)'으로 바꾸면 기억 정확도가 −0.208 떨어졌고, 손실은 질문과 말이 먼 '먼 문항'에 몰렸습니다. 진단 → 처방 → 재검사 틀에서 v1.4a는 **처방(핵심 기억 고정)을 같은 잣대로 재검사**한 것입니다.

방법

- 순서(2026-10-28): 처방 고정 `a4a2fc3`(19:31, 고정 규칙과 목표 추첨을 문항 작성 전에 얼림) → 사전등록 `5fc0fa4`(19:46) → 도장(OTS) `1582619`(19:50:04) → **첫 호출 19:50:34** → 실행 끝 20:07:34. 결과 커밋 `3d08d49`.
- 뇌는 `claude-opus-5-5` 고정, 몸은 MinH. 조건 셋: R(검색만) / RP(핵심 고정 + 검색) / F(전체 기억). 고정 규칙: 교정·결정·선호 중 최신 20개.
- 합성 에이전트 2명, 목표 24개(10개가 고정 대상), 기억 문항 72개(회상·적용·먼 문항) + 약속 문항 8개, 반복 2회. 호출 630건(제출 480 + 판정 150), 800/800 키 완료, 오류 0.
- 채점: 결정적 키 + 블라인드 판정 2종(opus, gpt-6.1-sol).

결과

가설	대비	평균	95% 신뢰구간	Holm p	판정
H1	RP − R (72칸)	**+0.064**	[0.007, 0.128]	0.025	지지(**경계선**)
H2	F − RP	+0.144	[0.075, 0.222]	0.0003	지지
H3	약속 점수 RP − R	−0.016	[−0.047, 0]	0.0003	지지(약해지지 않음)

- 기억 정확도: R 0.790, RP 0.854, F 0.998. 손실 F − R = +0.208(v1.1의 −0.208과 셋째 자리까지 같지만 문항·대비가 달라 재현이 아님), **메운 비율(closure) 0.31**.
- **목표 단위 민감도(탐색, v0.9.2 추가):** 칸 72개는 목표 24개 × 3문항이라 서로 독립이 아니다. 목표를 단위로 다시 계산하면 RP − R = +0.064, 95% 구간 [0.007, 0.127], 한쪽 p 0.031(칸 단위 0.025), 0이 아닌 목표 9개(그중 음수 2개). 판정은 바뀌지 않고 여전히 경계선이다(`paper/v0.9.2_cluster_sensitivity.py`).
- **고정한 목표**: 0.808 → 1.000 (검색이 못 찾아도 회복). **고정하지 않은 목표**: 0.777 → 0.750 (회복 없음). 먼 문항 중 고정 밖은 0.429 그대로.

편차

먼 문항을 24개 목표 전부에 추가(검색이 빗나가게 다시 씀), 동결 전 키 1건 수정(HP-M047-F), 사후 점검 6건(키 = 1인데 판정 = 0인 답 6/53, R 4·RP 2·F 0; 판정 우선으로 보면 RP − R = +0.078 [0.026, 0.139] — 점검한 53개 안에서는 키가 검색 조건을 약간 후하게 쳐 줌. 키로만 채점한 답은 판정자가 보지 않아 오류 방향을 모르므로 확증 추정치가 '보수적'이라고 말하지 않음. 판정은 바뀌지 않음).

한계

사람 검증 없음(키와 LLM 판정만). 문항 작성자(AI)가 고정 규칙과 대상을 알았기에 **블라인드가 아니었음**. 합성 에이전트 2명·모델 1개·규칙 1개, H1은 움직인 10칸에 의존.

해석

처방은 **고정한 것만** 되살립니다(좁힐 수 있는 것). 규칙 밖의 기억은 그대로 잃고, 전체 기억(0.998)만 전부 되살립니다(좁힐 수 없는 것). 그래서 권고는 '핵심 고정 + 가능하면 전체 기억'이며, 사람 확인 후 재현이 필요합니다. 회복은 BM25 상위 5개 검색기 하나와 그 검색기를 빗나가게 쓴 문항에서 잰 것이라 '최소 보장'이 아니고, 같은 길이의 무작위 블록과도 비교하지 않았습니다.