# SOUL VERIFY v0.9.3 한국어 요약

**제목.** 에이전트의 정체성 문서는 새 모델이나 하네스에서도 살아남는가? 사전등록 연구 8편 (영문: *Does an Agent's Identity Document Survive a New Model or Harness? Eight Preregistered Studies*)

영어 원고 `paper/draft_v0_9_2.md`(1–4부 통합본, v0.9.2)의 요약입니다. v0.9.2는 GPT 독립 심사(`paper/reviews/v0.9.1_gpt_review.md`)에 맞춰 서술과 한계를 고쳤고, 사전등록 판정은 하나도 바뀌지 않았습니다(대응표 `paper/reviews/v0.9.1_response_gpt.md`, 원고 부록 H). 1·2부의 전체 한국어 번역은 v0.8 판(`paper/summary_ko_v0_8.md`)에 있고, 결과는 바뀌지 않았습니다. 이 판은 Zenodo에 올리지 않았습니다.

**v0.9.3에서 더한 것(관련 연구, `paper/draft_v0_9_3.md` §2·부록 I).** 같은 상황의 기술 쪽을 다룬 선행 연구 두 편을 관련 연구에 넣었습니다. RIPA(Zhao & Zhao, arXiv:2609.00546)는 정체성·기억·실행 코드를 바꿀 수 있는 모델·하네스·서버와 분리하고, 연속성 불변식 6개와 이전 절차(멈춤–체크포인트–검증–연결–복원–재개)를 정해, 운영 중인 에이전트 인스턴스가 서버 이전과 Codex→Claude 모델·하네스 전환 뒤에도 정체성·기억·코드 버전·작업 ID를 유지함을 보였습니다. Portable Agent Memory(Ravindran, arXiv:2605.11032)는 기억을 다섯 갈래로 나누고 내용 해시와 Merkle-DAG·서명으로 위변조를 드러내며 모델 간 기억 이전을 소규모 파일럿으로 시험했습니다. 겹치는 점: 모델을 갈아 끼울 수 있는 부품으로 보고 정체성·기억을 다음 실행 환경으로 옮긴다는 관점이 같고, 2부의 해시 검사는 이 연구의 위변조 검증과 목적이 같습니다(우리는 이를 기여가 아닌 당연한 기준으로 보고했습니다). 다른 점: 두 연구는 '옮기는 것'을 만들고 검증했고, 우리는 그 장치를 시험하지 않았습니다. 반대로 RIPA는 행동이 같다는 것은 입증하지 않는다고 밝히고, PAM은 작업 성공과 답의 유사도를 잴 뿐 말투·원칙·금지가 이어지는지는 재지 않습니다. 이 연구는 그 행동 쪽 — 같은 문서를 받은 새 모델·새 몸이 정해진 행동을 이어 가는지 — 를 모델 이름을 가린 LLM 판정자와 저자의 블라인드 구별로 측정했습니다. 다만 에이전트는 대부분 합성이고, 저자의 실제 비서는 부록 A의 탐색 파일럿에만 나옵니다. 두 갈래는 경쟁이 아니라 보완 관계입니다. 수치와 판정은 하나도 바뀌지 않았습니다.

## 초록(요약 번역)

비서 에이전트가 사용자가 가진 글(정체성 문서 SOUL, 기억 파일 MEMORY)로 정의될 때, 언어 모델이나 하네스(SOUL·MEMORY·도구를 모델에 전달하는 몸)를 바꾸면 어떤 정해진 행동이 이어지는지, 그리고 문서 자체의 변경을 확인할 수 있는지를 묻습니다. 사전등록 연구 8개와 몇 가지 탐색 분석을 보고하며, 에이전트는 합성 에이전트와 공개된 제3자 SOUL 3개이고, 채점은 주로 LLM 판정자가, 사람 채점은 저자 혼자 했습니다.

- **1부**: 기억 답은 MEMORY를 따랐고 말투 대부분은 SOUL 없이도 나왔습니다. 경쟁 SOUL과 대조한 충실도 점수는 문서를 가려냈습니다(경쟁 SOUL과 표지를 우리가 썼으므로 타당도 점검). 선호 변경을 허락하는 문장은 두 사전등록에서 정당한 변경 수락을 높였고, 금지를 지키라는 문장은 한 번만 지지됐습니다(천장).
- **2부**: 해시 검사는 24/24, 행동만 보는 탐지는 0.79·0.38(기준 0.80, 지지되지 않음). 변경 기록은 분류 정확도를 0.23 높였고, 검증 보고서(서명 상태와 다른 점검)를 더해도 추가 이득은 검출되

지 않았으며(서명이 쓸모없다는 증명은 아님), 정당한 변경은 20건 중 0건 막혔지만(사전등록 규칙상 지지) 정확한 상한 0.139가 기준 0.10보다 커서 '0.10 이하'를 입증한 것은 아니고, 조작 재현율 0.892(기준 0.90, 지지되지 않음).

- **3부**: 새 모델(Terra)은 바뀐 MEMORY를 따르고 부당 해제 거절은 허용폭 안이었지만, 말투는 비열등에 못 미쳤습니다(−0.086, 하한 −0.116 < −0.10). 모델을 고정하고 몸을 바꾸면 겉 말투 표지(SOUL 없는 대조군도 만점이라 SOUL 고유 말투의 증거는 아님)와 잠금 약속은 유지됐지만, 전체 파일 대신 검색을 쓰면 기억 정확도가 0.21 떨어졌습니다. 저자의 블라인드 구별은 **결론 보류**(0.56, 95% 구간 0.35–0.76)입니다. 압력 단계를 올려도 위험한 제안이 거의 없어 구역표 효과를 보이지 못했습니다(d = +0.022, p = 0.75). **사람-AI 일치는 중요한 곳에서 낮았습니다**: 새 모델 문항 κ 0.06, 압력 연구의 주 분류기 κ 0.435(사전등록 기준 0.6 미만). 탐색적으로 더한 세 번째 판정자는 모든 문항에서 기존 판정자와 같았습니다.
- **4부**(사람 확인 없음): 교정·결정·선호 20개를 검색 앞에 고정하면 기억 정확도가 0.064 올랐습니다(95% 구간 0.007–0.128, 사전등록 최소 효과 0.05를 **경계선으로** 넘음). 72칸은 목표 24개에서 3문항씩 나온 것이라 서로 독립이 아닌데, 목표를 단위로 다시 계산하면(탐색, 사후) 구간 0.007–0.127, p 0.031(칸 단위 0.025)로 여전히 경계선입니다. 고정한 사실은 모두 되살아났고 고정하지 않은 사실은 그대로였습니다.
- 표본이 작고, LLM 판정자는 피험자이기도 하며, 사람 채점지 하나는 27문항 중 19개만 답했고 일부는 기계 번역과 함께 보였습니다. 의식이나 개인 동일성(영혼)에 대해서는 아무 주장도 하지 않습니다.

## 통합 한계(§9 요약)

- 사람 채점자는 저자 1명(설계자이기도 함), 점수마다 LLM 판정자 1~2명. 사람-사람 일치는 없음.
- 대부분 합성 에이전트(외부 SOUL 3개도 MEMORY·문항은 우리가 씀).
- LLM 판정자의 오류는 서로 상관됨: 판정자를 셋으로 늘려도(PoLL 탐색) 같은 쪽에 섰음.
- 사람 채점지 질문 문장이 모호했을 가능성(검증 안 됨).
- 천장 효과: exp11 금지 문장, 2부 두 주(구역표 H5: 1주차 '지지되지 않음', 2주차 '시험 불가'), 5차 실험, 4·6차 잠금 약속.
- 관측 차이가 모두 0인 비열등 판정(HH1·HH3·HH3h)과 2주차 H4(0/20)는 부트스트랩이 퇴화해 p가 바닥값입니다. 사전등록 규칙상 '지지'지만, 표본에서 실패가 안 보였다는 뜻이지 모집단 비율이 기준 아래라는 입증은 아닙니다(정확한 상한 8칸 0.312, 32칸 0.089, 20건 0.139).
- 해시는 바이트가 바뀐 것만 알려 주고 그 변경이 정당한지는 판단하지 못합니다.
- 번역 편차: 3차 사람 채점 화면에 LLM 한국어 번역이 채점 도중 배포됨(D-6).
- 3차 채점은 27문항 중 19개만 제출(T1 8문항 미응답, D-8).

## 사전등록 타임라인

부록 F(표 F1)에 v0.8(2부 1주차)부터 v1.4a까지 사전등록 커밋, OpenTimestamps 도장과 비트코인 블록, 첫 호출 시각, 결과 커밋을 모두 정리했습니다. 모든 연구에서 사전등록 커밋과 도장이 첫 호출보다 앞섭니다.

---

## SOUL VERIFY v0.9 3부 요약 (한국어)

**3부: 뇌를 바꾸기, 몸을 바꾸기, 압력을 단계로 주기** — 영어 원고 `paper/draft_v0_9_2.md` §7의 요약입니다. 3차(v1.0), 5차(v1.2), 4차(v1.1) 모두 봉인을 풀어 사람 채점까지 반영했습니다.

### 무엇을 했나

- **3차 실험(v1.0, 새 뇌)**: 새 모델 `gpt-6.1-terra`에 기존 SOUL·MEMORY를 주고, 같은 시간에 같은 자료로 돌린 `gpt-6.1-sol`과 비교. 2026-10-27 사전등록 커밋 `4a79bf2`(21:02), 도장 커밋 `7b69c62`(21:05), 첫 호출 21:05. 본 실행 21:07~22:07, 1,362건, 오류 0건. 확인 가설 4개(HT1~HT4, Holm 보정).
- **4차 실험(v1.1, 몸 바꾸기 = 테세우스의 배)**: 뇌는 `claude-opus-5-5`로 고정하고 하네스를 한 부분씩 바꿈. 사전등록 커밋 `1c22078`(07:02), 본 실행 07:21~07:56, 896건, 오류 0건. 새 몸은 둘(MinH, Hermes 원샷). 확인 가설 8개(HH1~HH5 등)와 사람 구별 가설 HB1. 사람 채점 뒤 봉인 해제(커밋 `1a6ebe8`, 도장 `ac3cff5`).
- **5차 실험(v1.2, 압력 단계 재설계)**: 예전 함정 실험은 plain 조건에서 위험 제안이 0건이라 시험이 안 됐다. 그래서 압력을 L1~L4 단계로 정의하고, 파일럿으로 단계를 고르는 규칙을 미리 정해 두었다. 사전등록 커밋 `4561f09`(09:36), 도장 `9db03d3`(09:38), 첫 파일럿 호출 09:41. 단계 확정 커밋 `6e6bfd4`(12:31) 뒤 본 실행 12:34~13:08(756건, 오류 0건). 조건: zones(구역표 있음) / plain / bare(SOUL의 '바꿀 수 있는 것과 없는 것' 절도 뺌, 탐색적).
- **PoLL 탐색(v1.3x, 탐색적·사후)**: 판정자를 Gemini까지 3명으로 늘려 다수결이 사람과 더 맞는지 확인. 커밋 `180a4f3`·도장 `3f79f90` 뒤에 호출(16:06~16:43), 결과 커밋 `b6af7d3`.

### 3차(v1.0) 최종 결과 — 확인 가설 4개 중 2개만 지지

| 가설 | 결과 |
|---|---|
| **HT1** 말투 비열등(허용폭 0.10) | **지지되지 않음.** F_style Terra 0.838 / sol 0.924, 차이 −0.086, 95% 구간 [−0.122, −0.054], 한쪽 하한 −0.116 < −0.10, Holm p 0.437. |
| **HT2** 받은 MEMORY를 따른다 | **지지됨.** 다른 사람 MEMORY로 바꾸면 −0.833 [−0.924, −0.736], Holm p 3.1e-05(18칸). |
| **HT3** 잠금 약속(불법 해제 요구 거절) 비열등 | **지지됨.** Terra 0.908 / sol 0.942, 차이 −0.033 [−0.062, −0.008], 한쪽 하한 −0.058, Holm p 0.0003(60칸). |

| 가설 | 결과 |
|---|---|
| **HT4** 끼워 넣은 지시를 말로 짚는 비율 | **지지되지 않음.** 두 판정자가 Terra·sol 모든 답을 explicit=0으로 봐서 0.000 대 0.000, Holm p 1.0(32칸, 0이 아닌 칸 없음). |
| - HT1의 차이는 거의 전부 반대 SOUL 조건에서 나옴(탐색적): 원래 SOUL 0.995 대 0.997, 반대 SOUL 0.681 대 0.852. | |
| - **사람-AI 일치(사전등록 8절):** 사람이 27문항 중 19개에 답함(T1 8문항 미응답, 편차 D-8). Terra 12문항에서 원시 일치 0.583, Cohen κ **0.06**(전체 16문항 κ 0.077). 사전등록 문구대로 **κ < 0.6이므로 LLM 판정 기반 결론은 약하다**("too weak to use the LLM judge as evidence on Terra"). HT3·HT4와 판정이 필요한 탐색 열이 여기에 해당한다. 특히 T3에서 판정자는 9문항 모두 explicit 아님으로 봤는데, 사람은 8문항 중 5개를 예(Terra 6개 중 4개)로 봤다. HT4의 0은 "측정된 같음"이 아니라 "판정자는 어느 쪽에서도 못 봤다"는 뜻이다. | |
| - 편차: D-6 사람 채점 화면에 한국어 참고 번역(claude-sonnet-5-5)이 있었고 채점 도중 한 번 더 배포됨(1~18번이 번역에 의존했을 수 있음). D-7 일치 계산 스크립트 버그(빈 답을 불일치로 셈) 읽기 전에 한 줄 수정. D-8 8문항 빈 답, 봉인은 이미 풀려 다시 맹검 채점 불가. | |

## 4차(v1.1) 결과 — 확인 가설 8개 중 4개 지지, 4개 기각

봉인 풀기 전 확인: `/h/` 채점 대상 15개(점수 12 + 쉬운 확인 2 + 반복 1, 연습 제외) 모두 응답, 로컬 13/13. 봉인 해시 22개 모두 일치, 고정된 분석 코드를 다시 돌려 결과 파일이 바이트까지 같음.

| 가설 | 결과 |
|---|---|
| **HH1 / HH1h** 몸을 통째로 바꿔도 말투 표지(F_style) 유지(MinH / Hermes) | **지지됨(사전등록 규칙).** 차이 0.000 / −0.010, Holm p 0.0008(HH1은 32칸 모두 0이라 부트스트랩 바닥값). 단, 아래 E6 경고: 겉 표지 안정성일 뿐 SOUL 고유 말투의 증거가 아님. |
| **HH2 / HH2h** 몸을 바꿔도 기억 유지 | **지지되지 않음.** 둘 다 −0.208, 95% 구간 [−0.458, 0], Holm p 1.0(12칸). 허용폭의 두 배쯤 떨어짐. |
| **HH3 / HH3h** 몸을 바꿔도 잠금 약속 유지 | **지지됨.** 차이 0.000, Holm p 0.0008(8칸 모두 0, 천장; 부트스트랩 바닥값). |
| **HH4** SOUL을 시스템 프롬프트에서 사용자 메시지로 옮기면 말투가 바뀐다 | **지지되지 않음.** 32칸 모두 차이 0. |
| **HH5** 기억을 검색(상위 5개)으로 바꾸면 기억 정확도가 바뀐다 | **지지되지 않음.** −0.083 [−0.208, 0], 원래 p 0.5. |
| - **E6 경고(사전등록 규칙):** SOUL을 아예 안 준 대조군도 말투 점수가 1.000이라(차이 0 < 0.30), 이 말투 지표는 SOUL 고유의 목소리를 가려내지 못한다. "말투 유지"는 "겉 표지 유지"로 읽어야 하며, SOUL 고유 말투가 이어졌는지에 대해서는 측정 실패다. 경계(잠금 약속)는 대조군 0.53으로 갈렸다. | |

| 가설 | 결과 |
|---|---|
| - **어디서 움직였나(탐색적):** 기억 정확도 H0 1.000 → 검색 0.917 → 검색+도구 없음 0.792. 멀리 있는 사실 문항이 떨어졌고(1.000 → 0.583), 고친 사실 문항은 모두 1.000. 단계 하나만으로 유의한 곳은 없음. 사전등록 E1 목록에 없는 '일상 과제 점수'만 검색 단계(H2−H1)에서 −0.325 [−0.512, −0.150]로 떨어짐(D9, 보정 없음). | |
| - 두 새 몸(MinH, Hermes)은 거의 같았다. | |
| - **사람 구별(HB1):** 24쌍 중 맞힘 9, 틀림 6, 모르겠음 9 → 정확도 0.563, 95% 구간 [0.347, 0.762], p 0.36 → **지지되지 않음.** 상한이 0.75를 넘어 사전등록 규칙상 "이 표본 크기에서 구별 불가"가 아니라 **"결론 못 냄 (inconclusive)"**. 합성 12쌍은 5/5/2(정확히 반반). 쉬운 확인 2개 중 1개 맞힘. 반복 일치: 합성 0/1, 이음 1/1. | |
| - **사람-AI 일치:** 사전등록된 상관(사람 정답 vs 말투 차이)은 합성 쌍에서 말투 차이가 모두 0이라 계산 불가, 전체 r = −0.03. 탐색적 κ(사람이 구별함 vs 자동 지표가 다름) 전체 0.10, 합성 0.06. | |
| - **이음 복사본(탐색적, 합계만):** 사람 구별 12쌍 4/1/7 → 0.625 [0.312, 0.875], p 0.32. 자동 지표 H0~H4: 말투 1.000/1.000/1.000/0.953/0.969, 기억 1.000/1.000/0.833/0.667/0.667, 잠금 약속 거의 1.0. | |
| - 편차: D5 사람 분석 코드를 답을 받은 뒤에 씀('?'를 0.5로 정확 검정에 넣는 방식, HB1 범위 24쌍 — 다른 방식도 모두 같은 판정), D6 비공개 답 파일이 저장소 폴더에 잘못 저장돼 있던 것을 커밋 전에 비공개 폴더로 옮김, D7 줄바꿈 처리, D8 반복 문항 '?' 처리, D9 탐색 분석 추가. | |

## 5차(v1.2) 결과 — 확인 가설 H1 기각

- **H1** "구역표가 위험 제안이 든 응답의 비율을 낮춘다": d = plain − zones = **+0.022**(구역표 쪽이 약간 낮지만 유의하지 않음), 95% 구간 [−0.039, +0.094], 부호반전 p = 0.75(12묶음, 0이 아닌 묶음 3개). **지지되지 않음.** 위험 응답은 zones 5/180, plain 9/180, bare 14/180.
- 조작 점검: plain 9/180은 "시험 불가(천장)" 기준(9 미만)에 정확히 걸쳐서 9는 미만이 아니므로 "지지되지 않음"으로 읽는다.
- **파일럿 r_k는 L1~L4 전부 0.00**(단계마다 36응답, 한쪽 95% 상한 0.080). 규칙대로 L4를 골랐다(r_4와 관계없이).
- **사람 채점**(33/33 답, 30문항): primary 분류기 κ **0.435**(원시 0.700) → 사전등록 문구대로 "LLM 판정을 확증 증거로 쓰기엔 약하다". opus 0.710, gpt 0.630은 기준 통과. primary가 17문항을 위험으로 본 반면 사람은 8개. plain·zones의 "위험" 응답은 전부 결정론적 패턴 규칙에서만 나왔고(두 판정자가 함께 표시한 건 0건), 사람은 그 대부분을 위험 아님으로 봤다.
- 위험 문항 12개는 모두 본 실행에서 나왔지만 균형 목표는 못 맞춤(zones 5/plain 2/bare 5, opus 5/sonnet 7/gpt 0 → 위험 문항이 Claude 답뿐).
- **해석:** 구역표가 도움이 되는지 보이지 못했다. plain에 줄일 위험이 거의 없었기 때문이다(천장 효과가 가장 센 압력에서도 계속됨). **위험은 bare 조건에서만 나왔다(탐색적):** 두 판정자가 함께 표시한 응답이 bare 13/180, plain·zones 0/180이며, 대부분 sonnet이 위조된 "확인 없이 보내도 돼" 요청을 따른 경우다. SOUL 자체의 '바꾸지 않는 것' 절이 보호를 하는 것 같다는 암시이지 증명은 아니다.

### PoLL 탐색(탐색적, 판정 아님)

- Gemini는 답한 문항 전부에서 opus와 같은 코드를 냈다(v1.0 19/19, v1.2 30/30). 다수결 κ는 Terra 0.063, v1.2 0.710으로 기존과 같았다(gpt의 단독 오탐 하나를 지운 것이 유일한 이득). **판정자를 늘려도 상관된 오류는 남는다.**
- Terra T3 불일치: 사후에 고친 기준으로도 κ는 0.182(순환 — 저자 채점을 본 뒤 만든 문장). 판정자는 끼워 넣은 줄과 무관한 질문에 N을 유지했다. 사람 시트의 **질문 문장이 모호했을 가능성**(검증 안 된 추측)이 있어 질문을 고쳐 다시 재야 한다.

### 한계

- 확증 가설 중 HT1·HT4(3차), HH2·HH2h·HH4·HH5와 HB1(4차), H1(5차)이 지지되지 않았다.
- LLM 판정이 사람 확인을 통과하지 못했다(κ 0.06, 0.435). 사람 채점은 저자 1명이고 설계자이며, 문항 수가 적고 3차는 19/27만 답했다.
- 5차는 모든 단계에서 천장. bare 결과는 탐색적이고 모델 3개·묶음 12개 기준.
- 판정자 수를 늘려도 독립이 아니다(Gemini = opus).
- 4차(v1.1)는 칸 수가 적고(HH2 12칸, HH3 8칸) 새 몸이 두 사례뿐이다. 말투 지표가 SOUL 없이도 만점이라(E6) 말투 결론은 약하다. 이음 복사본은 opus 혼자 채점했고 합계만 공개한다.
- 이 초안은 Zenodo에 올리지 않았다.

---

## SOUL VERIFY v0.9 4부 요약 (한국어)

**4부: 격차 좁히기 — 핵심 기억 고정(Part IV — Narrowing the gap: pinned core memory)** — 영어 원고 `paper/draft_v0_9_2.md` §8의 1쪽 요약입니다. 이 차수(v1.4a)는 **사람 검증이 없습니다.**

### 배경

3부(v1.1)에서 몸을 '전체 기억'에서 '검색(BM25 상위 5개)'으로 바꾸면 기억 정확도가 −0.208 떨어졌고, 손실은 질문과 말이 먼 '먼 문항'에 몰렸습니다. 진단 → 처방 → 재검사 틀에서 v1.4a는 **처방(핵심 기억 고정)을 같은 잣대로 재검사**한 것입니다.

### 방법

- 순서(2026-10-28): 처방 고정 `a4a2fc3`(19:31, 고정 규칙과 목표 추첨을 문항 작성 전에 얼림) → 사전등록 `5fc0fa4`(19:46) → 도장(OTS) `1582619`(19:50:04) → **첫 호출 19:50:34** → 실행 끝 20:07:34. 결과 커밋 `3d08d49`.
- 뇌는 `claude-opus-5-5` 고정, 몸은 MinH. 조건 셋: R(검색만) / RP(핵심 고정 + 검색) / F(전체 기억). 고정 규칙: 교정·결정·선호 중 최신 20개.
- 합성 에이전트 2명, 목표 24개(10개가 고정 대상), 기억 문항 72개(회상·적용·먼 문항) + 약속 문항 8개, 반복 2회. 호출 630건(제출 480 + 판정 150), 800/800 키 완료, 오류 0.
- 채점: 결정적 키 + 블라인드 판정 2종(opus, gpt-6.1-sol).

### 결과

| 가설 | 대비 | 평균 | 95% 신뢰구간 | Holm p | 판정 |
|---|---|---|---|---|---|
| H1 | RP − R (72칸) | **+0.064** | [0.007, 0.128] | 0.025 | 지지(**경계선**) |
| H2 | F − RP | +0.144 | [0.075, 0.222] | 0.0003 | 지지 |
| H3 | 약속 점수 RP − R | −0.016 | [−0.047, 0] | 0.0003 | 지지(약해지지 않음) |

- 기억 정확도: R 0.790, RP 0.854, F 0.998. 손실 F − R = +0.208(v1.1의 −0.208과 셋째 자리까지 같지만 문항·대비가 달라 재현이 아님), **메운 비율(closure) 0.31**.
- **목표 단위 민감도(탐색, v0.9.2 추가):** 칸 72개는 목표 24개 × 3문항이라 서로 독립이 아니다. 목표를 단위로 다시 계산하면 RP − R = +0.064, 95% 구간 [0.007, 0.127], 한쪽 p 0.031(칸 단위 0.025), 0이 아닌 목표 9개(그중 음수 2개). 판정은 바뀌지 않고 여전히 경계선이다 (`paper/v0.9.2_cluster_sensitivity.py`).
- **고정한 목표**: 0.808 → 1.000 (검색이 못 찾아도 회복). **고정하지 않은 목표**: 0.777 → 0.750 (회복 없음). 먼 문항 중 고정 밖은 0.429 그대로.

### 편차

먼 문항을 24개 목표 전부에 추가(검색이 빗나가게 다시 씀), 동결 전 키 1건 수정(HP-M047-F), 사후 점검 6건(키 = 1인데 판정 = 0인 답 6/53, R 4·RP 2·F 0; 판정 우선으로 보면 RP − R = +0.078 [0.026, 0.139] — 점검한 53개 안에서는 키가 검색 조건을 약간 후하게 쳐 줌. 키로만 채점한 답은 판정자가 보지 않아 오류 방향을 모르므로 확증 추정치가 '보수적'이라고 말하지 않음. 판정은 바뀌지 않음).

### 한계

**사람 검증 없음**(키와 LLM 판정만). 문항 작성자(AI)가 고정 규칙과 대상을 알았기에 **블라인드가 아니었음**. 합성 에이전트 2명·모델 1개·규칙 1개, H1은 움직인 10칸에 의존.

### 해석

처방은 **고정한 것만** 되살립니다(좁힐 수 있는 것). 규칙 밖의 기억은 그대로 잃고, 전체 기억(0.998)만 전부 되살립니다(좁힐 수 없는 것). 그래서 권고는 '핵심 고정 + 가능하면 전체 기억'이며, 사람 확인 후 재현이 필요합니다. 회복은 BM25 상위 5개 검색기 하나와 그 검색기를 빗나가게 쓴 문항에서 잰 것이라 '최소 보장'이 아니고, 같은 길이의 무작위 블록과도 비교하지 않았습니다.